

Trabajo Práctico 1:

“Análisis comparativo de modelos de machine learning para predicción de la deserción de estudiantes de educación superior”

Grupo N° 8

Daniela Carbonell, Silvana Contreras, Christian Lombardo

Octubre 2025

Abstract:

La deserción estudiantil en universidades argentinas alcanza niveles críticos, con solo el 12% de graduación entre ingresantes. Este trabajo compara modelos de machine learning supervisado para predecir la deserción universitaria a partir de datos académicos, demográficos y socioeconómicos de 57.510 estudiantes durante su primer año de cursada en una institución de educación superior argentina. Se evaluaron dos esquemas de clasificación: binaria (desertor vs. no desertor) y ternaria (desertor, graduado, en curso), aplicando regresión logística, SVM, árboles de decisión, KNN, AdaBoost y Random Forest. Los resultados muestran que la regresión logística alcanza el mejor desempeño en clasificación binaria, mientras que AdaBoost logra la máxima capacidad de detección en clasificación ternaria. El análisis de importancia de atributos revela consistencia entre todos los modelos: el rendimiento académico del primer año -específicamente los ratios de materias aprobadas sobre inscritas- constituye el predictor más potente de deserción, superando ampliamente a factores sociodemográficos tradicionales. El compromiso económico-administrativo, medido por el pago de matrícula, también muestra relevancia predictiva. Los hallazgos validan la aplicabilidad de sistemas de alerta temprana basados en machine learning para el contexto universitario argentino, sugiriendo que las intervenciones institucionales deberían focalizarse prioritariamente en el acompañamiento académico durante los primeros semestres.

Introducción¹

La deserción estudiantil en el nivel universitario constituye una de las principales problemáticas del sistema de educación superior argentino. Según la Secretaría de Políticas Universitarias, solo el 12 % de los estudiantes que ingresan a universidades nacionales logran graduarse (SPU, 2021), lo que refleja la magnitud de un fenómeno de carácter multifactorial que combina condicionantes económicos, educativos e individuales. Este trabajo analiza los factores asociados a la permanencia y el abandono, con el objetivo de responder a la pregunta: ¿qué variables permiten anticipar la probabilidad de deserción de un estudiante universitario? Se espera que las variables académicas (rendimiento en el primer año, unidades aprobadas, promedio de notas), socioeconómicas (ingresos familiares, tipo de beca) y demográficas (edad, estado civil, género) sean las más influyentes, dado su impacto comprobado en la bibliografía explorada. El problema se abordará mediante modelos de aprendizaje automático supervisado, que permitirán comparar distintos enfoques predictivos y evaluar su capacidad de generalización frente a datos reales de una institución de educación superior argentina.

Diversos estudios han tratado esta temática desde perspectivas institucionales y predictivas. La Comisión Nacional de Evaluación y Acreditación Universitaria (CONEAU) señala que, pese al incremento sostenido de la matrícula, cerca del 40 % de los ingresantes no se reinscribe al año siguiente (CONEAU, 2023). También el estudio de Pustilnik et al. (2023), constituye un avance, pero todavía se requiere profundizar en el análisis comparativo de modelos y en la interpretación de los factores subyacentes. En este sentido, el presente

¹ Acceso al código que respalda este trabajo en: https://github.com/SilvanaBContreras/AA_TP1_G8

trabajo busca contribuir a ese vacío empírico, evaluando la aplicabilidad de distintos algoritmos clásicos y de última generación en un contexto nacional.

En este marco, el objetivo es desarrollar y comparar modelos de clasificación que permitan predecir la deserción universitaria a partir de información académica, demográfica y socioeconómica disponible durante el primer año de cursada. Se aplicarán modelos de aprendizaje automático supervisado, evaluando su desempeño mediante métricas estándar y curvas de complejidad. El análisis busca, además, identificar las variables más influyentes en la permanencia estudiantil, con el propósito de aportar evidencia empírica que contribuya al diseño de estrategias institucionales orientadas a reducir el abandono y favorecer la graduación.

Materiales y métodos:

Datos / Variables explicativas:

El conjunto de datos utilizado proviene de una institución universitaria argentina y fue provisto en el marco de la consigna del trabajo práctico. Contiene información académica, demográfica y socioeconómica de estudiantes matriculados en diferentes carreras (química, diseño, educación, ingeniería, periodismo, economía, entre otras). La muestra está compuesta por 57.510 registros y 28 variables originales, relevadas al momento de la inscripción y durante el primer año de cursada. Se trata de una base curada y consistente, sin valores extremos ni registros sin información, por lo que las tareas de limpieza e imputación fueron mínimas.

Las variables disponibles incluyen tanto atributos numéricos —como la edad, el puntaje de ingreso, las calificaciones promedio y la cantidad de unidades curriculares inscritas y aprobadas— como atributos categóricos y ordinales, entre ellos el sexo, el estado civil, el nivel educativo y la demanda cognitiva de los padres, los ingresos familiares, la modalidad de cursada y la carrera elegida. Para posibilitar el uso de modelos numéricos, todas las variables categóricas fueron transformadas para que los modelos estadísticos y de machine learning puedan aprender relaciones significativas entre predictores y clases (James et al., 2021). En primer lugar, se redefinieron los niveles de ciertas categorías con baja frecuencia o alta redundancia: como estado civil. Las variables ordinales —como Estudios máximos antes de la inscripción, Ingresos del padre y la madre y Demanda cognitiva de los padres— fueron codificadas numéricamente según escalas jerárquicas explícitas. Las variables binarias se pasaron a valores 0/1, y las nominales se representaron mediante one-hot encoding. Finalmente, se añadieron atributos derivados relevantes para la predicción, como los ratios de materias aprobadas sobre inscritas en cada semestre y el lag de rendimiento académico (diferencia entre las notas promedio del segundo y el primer semestre), que capturan la evolución temprana del desempeño estudiantil. Se habían creado otras features originales pero luego de identificar su alta correlación con las preexistentes (>0.8) se decidió descartarlas. Adicionalmente, se observó la alta correlación entre las unidades curriculares inscritas (de 1er y 2do semestre) y unidades aprobadas (1er y 2do semestre). Con este hallazgo se generaron dos datasets separados y se los probó con el modelo de regresión logística, donde se encontró que rendía mejor el modelo que conservaba todas las variables, por esta razón se decidió no eliminarlas del dataset.

Como resultado, el conjunto final de predictores quedó conformado por 51 variables numéricas. En la Tabla 1 se resumen las principales características de las variables del conjunto transformado (X_{transf}), incluyendo su tipo, cantidad de valores únicos y rango de variación.

Los datos se dividieron en entrenamiento y prueba con un split estratificado 70/30, preservando la proporción de clases para evitar sesgos de muestreo; luego, durante la optimización de hiperparámetros, se aplicó validación cruzada estratificada de cinco pliegues para estimar la capacidad de generalización y reducir la dependencia de una única partición, siguiendo recomendaciones clásicas sobre prevención del sobreajuste (Bishop & Nasrabadi, 2006; Duda, Hart & Stork, 2001). Complementariamente, se analizaron curvas de complejidad—en particular, la profundidad en árboles de decisión y la regularización en regresión logística—para detectar señales de overfitting y elegir configuraciones que maximicen el desempeño en validación sin comprometer la generalización.

Tabla 1. Características de las variables del conjunto transformado.

Variable	Tipo	Únicos	Media	Min	Max	Mediana
Asistencia_diurna/nocturna_transformed	int64	2	0.93	0	1	1
Carrera (16 variables)*	int64	2	-	0	1	-
Cantidad_de_evaluaciones_en_el_1er_semestre	int64	35	8.29	0	45	8
Cantidad_de_evaluaciones_en_el_2do_semestre_	int64	31	8.35	0	33	8
Cualificación_promedio_de_estudios_previos	int64	47	69.8	50	97	70
Demanda_Cog_Madre_label_transformed	int64	5	2.28	1	5	2
Demanda_Cog_Padre_label_transformed	int64	5	2.28	1	5	2
desplazado_label_transformed	int64	2	0.61	0	1	1
Edad_al_momento_de_la_inscripción	int64	46	21.11	17	70	19
Estado_civil (4 variables)**	int64	2	-	0	1	-
Estudiante_Internacional_transformed	int64	2	0.006	0	1	0
Estudios_máximos_antes_de_la_inscripción_label_transf	int64	5	2.04	0	4	2
Ingresos_Madre_label_transformed	int64	5	2.12	1	5	2
Ingresos_Padre_label_transformed	int64	5	2.12	1	5	2
lag_nota_promedio_fe	int64	59	0.01	-35	35	0
Modo_aplicacion (4 variables)***	int64	2	-	0	1	-
Necesidades_educativas_especiales_transformed	int64	2	0.004	0	1	0
Nota_promedio_en_el_1er_semestre	int64	42	63.54	38	94	63
Nota_promedio_en_el_2do_semestre	int64	42	63.55	49	90	63
Pago_de_matrícula_al_día_transformed	int64	2	0.96	0	1	1
Poseedor_de_Beca_transformed	int64	2	0.31	0	1	0
Puntaje_en_examen_de_ingreso	int64	48	66.33	50	100	66
ratio_aprobadas_inscrito_1sem_fe	float64	151	0.9	0	2000	1
ratio_aprobadas_inscrito_2sem_fe	float64	139	1.15	0	16000	0.87
sexo_label_transformed	int64	2	0.24	0	1	0
Tiene_deuda_transformed	int64	2	0.04	0	1	0
Unidades_curriculares_1er_semestre_(aprobadas)	int64	23	5.43	0	26	6
Unidades_curriculares_1er_semestre_(inscrito)	int64	23	6.23	0	26	6
Unidades_curriculares_2do_semestre_(aprobadas)	int64	21	5.31	0	20	6
Unidades_curriculares_2do_semestre_(inscrito)	int64	22	6.27	0	23	6

* Carrera (16): Agronomía, Derecho, Diseño Multimedia, Diseño de Comunicación, Economía, Enfermería, Física, Gestión, Ingeniería Informática, Periodismo y Comunicación, Psicología, Publicidad y Marketing, Química, Sociología, Turismo, Veterinaria.

** Estado_civil (4): Soltero, Casado/Unión de Hecho, Viudo, Divorciado/Separado.

*** Modo_aplicacion (4): Acceso General, Acceso para Titulados, Acceso por Normativa Especial, Contingente Especial.


Variable respuesta / Tarea objetivo:

La variable de salida del conjunto de datos original describe la situación académica final del estudiante en tres categorías mutuamente excluyentes: “Graduado”, “En curso” y “Desertor”. Para su análisis se definieron dos esquemas: clasificación binaria y clasificación multiclase (ternaria) con el fin de explorar tanto la predicción temprana del abandono como la capacidad del modelo para distinguir entre trayectorias académicas de distinto desenlace.

En el esquema binario, se generó la etiqueta `target_binaria`, donde la clase “Desertor” fue codificada como 1 (positiva) y las clases “En curso” y “Graduado” se agruparon bajo la categoría 0 (no desertor). Esta decisión responde al objetivo principal del estudio: detectar tempranamente a los estudiantes con mayor probabilidad de abandono. En el esquema multiclase, se creó la etiqueta `target_ternaria`, con las tres categorías originales (Ver Figura 1). El conjunto presenta un desbalance moderado, con aproximadamente

un tercio de estudiantes que continúan o se gradúan frente a dos tercios que abandonan. Dado que la proporción no resulta severa, se decidió no aplicar técnicas de submuestreo ni sobremuestreo, priorizando mantener la estructura original de los datos. No obstante, para mitigar el impacto del desbalance, se eligieron métricas de evaluación sensibles a la distribución de clases, como recall, F1-score y área bajo la curva ROC (AUC) y se incluyeron hiperparámetros relevantes en las optimizaciones de modelos.

Figura 1. Distribución de la variable objetivo (binaria y ternaria).



Manejo de datos y esquemas de clasificación:

Clasificación binaria

La creación y características del target y el split entre train y test se explicitaron en la sección anterior. Para la clasificación con target binario se entrenaron modelos clásicos como regresión logística, máquinas de soporte vectorial (SVM) y árboles de decisión.

Tabla 2. Comparación de los hiperparámetros considerados para cada modelo de clasificación binaria.

	Regresión logística		Árboles de decisión		SVM	
	Rango	Óptimo	Rango	Óptimo	Rango	Óptimo
CV Folds	5		5		3	
método optim.	RandomizedSearchCV		GridSearch, Randomized	GridSearch	Optuna (Bayesiana)	
iteraciones	1000				15	
métrica	F1	0.890	ROC AUC	0.91 ± 0.0019	F1	0.896
C	0.001, 0.01, 0.1, 1, 10	0.01			0.001 - 1000	0.06
Penalty	l1, l2	l2				
Solver	liblinear, saga	liblinear				
class_weight	None, balanced	None	None, balanced	None	None, balanced	None
criterion			gini, entropy	gini		
max_depth			3, 5, 7, 10, 12, 14, 16, None	10		
min_samples_split			10, 20, 50, 100	10		
min_samples_leaf			5, 10, 15, 30, 40, 50	50		
ccp_alpha			0.0, 0.001, 0.005, 0.01, 0.05	0.0		
max_features			None, "sqrt", "log2"	None		
kernel					lineal y poly	lineal

Comparación de hiperparámetros utilizados en cada modelo, con sus rangos y valores finales seleccionados.

Específicamente para los árboles de decisión se exploraron distintos esquemas de optimización. Partiendo de un modelo de base con los hiperparámetros por defecto, se optimizó un modelo con

RandomizedSearchCV y un modelo con GridSearchCV que fue el seleccionado porque obtuvo el mejor recall, AUC del modelo y clasificación de la clase Desertor. Observamos sobre un modelo de base el impacto de tratar o no el desbalanceo con el hiperparámetro `class_weight`: no cambió en accuracy pero sí en la matriz de confusión, por eso se incluyó este hiperparámetro en las optimizaciones de árboles.

Posteriormente, se implementó un ensamble de los modelos anteriores mediante técnica de voting como se verá en la sección Resultados.

Clasificación multiclase

En una segunda etapa se trabajó con un esquema de clasificación multiclase (explicado en "Variable respuesta"). Se realizó una nueva separación de datos estratificada y en proporciones 70/30 para entrenar los modelos KNN, árboles de decisión, AdaBoost y Random Forest. Estos modelos tienen soporte nativo para múltiples clases por lo tanto fueron entrenados sin esquemas de reducción One vs. Rest o One vs. One. Esta decisión evita entrenar múltiples clasificadores binarios y optimiza de forma conjunta el desempeño global (F1 ponderado), lo que resultó adecuado dada la presencia de desbalance entre clases. Algoritmos como AdaBoost soportan clasificación multiclase de manera nativa requiriendo únicamente que cada clasificador débil tenga un desempeño mejor que una predicción aleatoria (Zhu et al., 2009). Por su parte, Random Forest y árboles de decisión pueden manejar naturalmente problemas de clasificación binaria o multiclase, ya que cada árbol se induce desde una muestra bootstrap del conjunto de entrenamiento y los nodos hoja pueden referirse a cualquiera de las K clases consideradas (Chen et al., 2004). Finalmente, k-Nearest Neighbors clasifica directamente instancias multiclase mediante votación por mayoría sobre las K clases en el vecindario, evitando la necesidad de descomposición del problema (Cover & Hart, 1967).

Tabla 3. Comparación de los hiperparámetros considerados para cada modelo de clasificación ternaria.

	Árboles de decisión		KNN		AdaBoost		Random Forest	
	Rango	Óptimo	Rango	Óptimo	Rango	Óptimo	Rango	Óptimo
CV Folds estrat.	5	-	5	-	5		5	-
método	GridSearch	-	RandomizedSearch	-	RandomizedSearch		RandomizedSearch	-
iter	-	-	50	-	-	-	20	-
métrica	F1-weighted	0.7706	F1-weighted	0.74	F1-weighted	0.7746	F1-weighted	-
class_weight	None, balanced	-	-	-	-	-	None, balanced, balanced_subsample	None
criterion	gini, entropy	entropy					Gini	Gini
max_depth	3, 5, 7, 10, 12, 14,, None	10			1	1	3-20	17
min_samples_split	10, 20, 50, 100	10					2-20	8
min_samples_leaf	5, 10, 15, 30, 40	40					1-10	8
ccp_alpha	0.0, 0.001, 0.005, 0.01, 0.05	0.0						
max_features	None, "sqrt", "log2"	None					None, "sqrt", "log2"	None
n_estimators					50, 301	295	100-10000	221
learning_rate					0.01, 1	0.95		
n_neighbors			(1,30)	11				
weights			(uniform, distance)	uniform				
metric			(euclidean, manhattan, minkowski)	minkowski				
p			(1,2)	2				
bootstrap							TRUE, FALSE	TRUE

Comparación de hiperparámetros utilizados en cada modelo, con sus rangos y valores finales seleccionados.

Finalmente, se incluyen ensambles basados en árboles: un modelo de Boosting (AdaBoost) y uno de Bagging (Random Forest).

En el caso específico de AdaBoost según explican Zhu et al. (2009) el algoritmo SAMME.R (disponible en SciKit Learn 1.3.2) es el óptimo para problemas multiclase porque usa probabilidades continuas y converge más rápido). Por esa razón se aplicó este algoritmo que no es el default del framework para comparar sus resultados y elegir el óptimo para el problema analizado. Aunque SAMME.R mejoró el desempeño en clases minoritarias (+2.4% recall en Graduado), SAMME (default en SciKit Learn 1.61) resultó superior para el objetivo de detección de deserción, con overfitting prácticamente nulo. No se incluyó un tratamiento específico del desbalanceo porque AdaBoost realiza un `sample_weight` interno que ajusta pesos por instancia en cada iteración (Freund & Schapire, 1997).

Evaluación de modelos

Se aplicaron las métricas accuracy, precisión, recall, F1-score y área bajo la curva ROC (AUC). También se utilizó la función de costo Log Loss en el caso de la regresión logística. El uso combinado de estas métricas responde al enfoque clásico de evaluación de clasificadores supervisados (Mitchell, 1997).

El AUC-ROC fue elegido como métrica central para comparar la capacidad discriminativa de los modelos sin depender de un umbral de decisión fijo y como una métrica más apropiada en un conjunto de datos con desbalance, frente a la accuracy. El recall (sensibilidad) fue la otra métrica considerada clave dado el objetivo del trabajo, que busca maximizar la detección temprana de los casos de riesgo de deserción y minimizar los falsos negativos (no detectar desertores).

El F1-score se utilizó como medida de equilibrio entre precisión y recall. En la clasificación multiclase se adoptó la métrica F1 ponderada (F1-weighted), que promedia los valores de F1-score de cada clase ponderándolos por su frecuencia relativa. Esta métrica resulta especialmente adecuada para datasets con clases desbalanceadas. En el caso de la regresión logística, se calculó la función Log Loss para evaluar la calidad de las probabilidades generadas por el modelo y su calibración.

Se trabajó íntegramente en Python, utilizando librerías y frameworks estándar para análisis estadístico y aprendizaje automático.

Resultados


La clasificación con target binario se realizó con modelos de regresión logística, máquinas de soporte vectorial (SVM) y árboles de decisión. Además luego se realizó un ensamble de los mismos por voting. Para la clasificación con target ternario se entrenaron modelos KNN, árboles de decisión, un ensamble por boosting como AdaBoost y un ensamble por bagging como Random Forest. A continuación se reportan los hallazgos observados en la performance de cada modelo para la tarea de predecir/identificar la clase Desertor. Se incluyen las curvas de complejidad para mostrar el desempeño de cada modelo en función de los hiperparámetros seleccionados y la capacidad de generalización. Sobre el final de esta sección se incluye la *Tabla 4. "Resumen de resultados según modelo"* que permite leer simultáneamente todos resultados obtenidos. Y por último, se agrupan los hallazgos sobre los factores más influyentes en la deserción identificados a través del análisis de la importancia de atributos.

Clasificación Binaria

El modelo de **Regresión Logística** (RL) alcanzó un desempeño sólido con Accuracy = 0.856, Recall = 0.918, Precision = 0.859, F1 = 0.888, AUC = 0.917 y Log Loss = 0.344. La matriz de confusión muestra 9.824 desertores correctamente identificados con solo 882 falsos negativos -casos donde se pierde la oportunidad de intervenir a tiempo- y 4.941 no desertores bien clasificados con 1.606 falsos positivos, evidenciando buen equilibrio entre sensibilidad y precisión. El Log Loss de 0.344 indica probabilidades bien calibradas con penalización moderada de errores y coherencia entre confianza y etiquetas reales. En la curva de complejidad (Ver Figura 2), usando C (inverso de la regularización) como control de flexibilidad, train y validation suben rápidamente desde C bajos y se estabilizan cerca de $AUC \approx 0.92$ para $C \geq 0.01$, con gap mínimo entre ambas que sugiere alta generalización y ausencia de sobreajuste; el óptimo en $C=0.01$,


coincidente con el óptimo de RandomizedSearchCV, se ubica en la zona donde no hay tanta diferencia entre el score de train y el score en test, maximizando rendimiento sin aumentar varianza.

Figura 2. Curva de complejidad del modelo de Regresión Logística.




El modelo **árboles de decisión** (ADD) obtuvo accuracy 85%, AUC 0.91 y recall 0.91 para la clase positiva, identificando correctamente 9.729 desertores y dejando 977 falsos negativos; en términos operativos, prioriza la sensibilidad sobre la especificidad, decisión apropiada para evitar omitir casos de abandono. La curva de complejidad (Ver Figura 3) en función de max_depth mostró un aumento sostenido del AUC hasta estabilizarse cerca de 0.91 alrededor de 10 niveles, con mínima brecha entre entrenamiento y validación, lo que indica ausencia de sobreajuste y buena generalización.

Figura 3. Curva de complejidad del modelo de Árboles de decisión.



El modelo **Support Vector Machines** (SVM) obtuvo accuracy 85.6%, recall 0.917 y precisión 0.860 para la clase positiva, identificando correctamente 9.820 desertores con 886 falsos negativos. La curva de complejidad (Ver Figura 4) en función del grado del kernel polinómico mostró que degree = 1 (kernel lineal) alcanza el máximo rendimiento en validación, mientras que el incremento del grado polinómico mantiene scores constantes pero inferiores, lo que sugiere que los datos son linealmente separables en el espacio de características y que agregar complejidad no lineal no aporta capacidad discriminativa adicional, confirmando la eficiencia del hiperplano lineal para este problema.

Figura 4. Curva de complejidad del modelo de Support Vector Machines (SVM).




El **ensamble** de los modelos previos de RL, SVM y ADD mediante **estrategia de votación**, obtuvo recall 0.917, precisión 0.860 y F1 0.888, identificando correctamente 9.820 desertores con 886 falsos negativos. El ensamble prioriza la sensibilidad sobre la especificidad, manteniendo un alto nivel de detección de casos de abandono mientras controla razonablemente los falsos positivos, lo que resulta apropiado para un sistema de alerta temprana donde omitir un desertor tiene mayor costo que intervenir sobre un falso positivo.

Clasificación Ternaria

El modelo de **árboles de decisión** (ADD) mostró desempeño moderado: accuracy 49% y F1 ponderado 0.48; la matriz de confusión indica mejor discriminación de Desertor (9.777, recall 0.66, F1 0.64) y menor rendimiento en En curso (recall 0.26, F1 0.26) y Graduado (recall 0.10, F1 0.12). Con class_weight=None, el algoritmo favorece la clase dominante y representa peor a las minoritarias; al repetir el modelo con ponderación de clases, mejoró el recall de Graduado, pero empeoró el recall de Desertor. La curva de complejidad (Ver Figura 5) muestra aumento sostenido del F1 ponderado (train/validación) hasta max_depth ≈ 10, óptimo de GridSearchCV; desde allí, la validación se estabiliza y la brecha se mantiene controlada, sugiriendo ausencia de sobreajuste y generalización adecuada, aunque con capacidad limitada para capturar patrones sutiles en clases menos representadas.


Figura 5. Curva de complejidad del modelo de Árbol de decisión.



En el caso del modelo **K-Nearest Neighbors (KNN)** para evitar el sesgo que generan las variables con distinta escala, se aplicó un StandardScaler, que transforma cada variable para que tenga media 0 y desviación estándar 1. Este proceso se incorporó dentro de un Pipeline junto al modelo KNeighborsClassifier,


garantizando que el escalado se aplique correctamente dentro de cada pliegue de la validación cruzada, evitando así data leakage. El modelo KNN, alcanzó accuracy 76% y F1 ponderado 0.74 refleja un desempeño moderado al promediar las tres clases, aunque con margen de mejora en la identificación de estudiantes en curso y graduados. El modelo alcanzó su mejor desempeño en la clase Desertor, con una precisión del 83% y un recall del 92%, lo que significa que detecta correctamente la mayoría de los desertores y comete pocos falsos positivos. La matriz de confusión muestra alta discriminación de Desertor (9.808 aciertos), pero menor rendimiento en Graduado (recall 0.35, F1 0.46) y En Curso (recall 0.58, F1 0.58), con confusiones marcadas entre estas dos clases (922 Graduados clasificados como En Curso y 1.493 En Curso clasificados como Desertor). En su curva de complejidad (Ver Figura 6) podemos ver cómo ésta aumenta inversamente al número de vecinos, teniendo una diferencia alta en score entre train y test para valores chicos de este parámetro.

Figura 6. Curva de complejidad del modelo de K-Nearest Neighbors (KNN).



El modelo **AdaBoost** (ADA) mostró desempeño sólido con accuracy 78% y F1 ponderado 0.77; la matriz de confusión indica alta discriminación de Desertor (9.979 aciertos, recall 0.93, F1 0.89), pero menor rendimiento en En Curso (recall 0.60, F1 0.61) y Graduado (recall 0.44, F1 0.54), con confusiones marcadas entre Graduado y En Curso (847 y 464 errores, respectivamente), señal de traslape de rasgos entre ambas. La curva de complejidad (Ver Figura 7) muestra incremento sostenido del F1 macro hasta $n_estimators \approx 295$ (óptimo por RandomizedSearchCV), tras lo cual train y validación convergen y se estabilizan en torno a 0.775, con gap mínimo 0.0001 (train 0.7747 vs val 0.7746), lo que sugiere ausencia de overfitting y generalización robusta, aunque el plateau evidencia un límite de capacidad sin capturar mejor las clases minoritarias. El ROC-AUC OvO macro = 0.82 confirma mayor capacidad discriminativa que árboles simples, mostrando que el boosting refina las fronteras de decisión.

Figura 7. Curva de complejidad del modelo de AdaBoost.



El modelo **Random Forest** (RF) mostró desempeño sólido con accuracy 79% y F1 ponderado 0.78; la matriz de confusión indica alta discriminación de Desertor (9.956 aciertos, recall 0.93, F1 0.89), pero menor rendimiento en las clases minoritarias. El ROC-AUC OvO macro confirma capacidad discriminativa robusta, mostrando que el ensemble de árboles logra refinar las fronteras de decisión mediante agregación de múltiples clasificadores débiles, aunque persiste la dificultad para capturar adecuadamente las clases minoritarias debido al desbalance inherente del dataset. La curva de complejidad (Ver Figura 8) muestra un punto de quiebre entre ambos scores a partir de un max depth igual a 5, lo que difiere con el encontrado por la búsqueda de hiperparametros dado en 17.

Figura 8. Curva de complejidad del modelo de Random Forest.




Tabla 4. Resumen de resultados según modelo.

	Clasificación Binaria				Clasificación Ternaria			
	Regresión Logística	Árboles de decisión	SVM	Ensamble	Árboles de decisión	KNN	AdaBoost	Random Forest
Accuracy	0.856	0.85	0.855	.	0.49	0.76	0.783	0.79
Precisión	0.859	0.86	0.860	0.860	0.62	0.83	0.848	0.85
Sensibilidad	0.918	0.91	0.917	0.917	0.66	0.92	0.932	0.93
F1	0.888	0.88	0.887	0.888	-	-	-	0.89
F1_weighted	-	-	-		0.48	0.74	0.772	0.78
AUC	0.917	0.9084	-		-	-	-	-
Verdaderos Desertores Detectados	9824	9729	9820	9820	9777	9808	9979	9956

A partir del análisis de **importancia de atributos** de los modelos evaluados, se observa que los factores más determinantes en la predicción de la deserción universitaria están directamente relacionados con el rendimiento académico durante el primer año. Los ratios de materias aprobadas sobre inscritas en el segundo y primer semestre concentran más del 85% de la ganancia de información en los modelos de árboles binarios, mientras que en Random Forest (clasificación ternaria) el ratio del segundo semestre alcanza el 49% de importancia y el del primer semestre el 7.8%, totalizando cerca del 57% entre ambos. En regresión logística, el ratio de aprobadas sobre inscrito del primer semestre presenta el coeficiente estandarizado más alto en magnitud absoluta (7.33), seguido por las unidades curriculares aprobadas del segundo (1.57) y primer semestre (1.04), confirmando que cada materia aprobada en el segundo semestre multiplica por 2.37 las probabilidades de no desertar. En AdaBoost, el ratio del segundo semestre alcanza el 25.7% de importancia, y junto con el pago de matrícula (18.7%) y el ratio del primer semestre (8.9%), explican más del 53% de la capacidad predictiva del modelo. El modelo SVM confirma este patrón: las unidades curriculares aprobadas en el segundo semestre presentan la mayor importancia (1.14), seguidas por las del primer semestre (0.58) y las materias inscritas del segundo semestre (0.55).

Variables vinculadas con el acceso y la permanencia institucional también contribuyeron al poder predictivo, aunque en menor magnitud. El pago de matrícula al día mostró particular relevancia en regresión logística con un odds ratio de 9.75, lo que implica que los estudiantes con pagos actualizados tienen casi diez veces más probabilidad de no desertar, sugiriendo que el compromiso económico y administrativo está fuertemente asociado a la continuidad académica. En AdaBoost, esta variable representa el 18.7% de la importancia, en SVM alcanza 0.34, y en Random Forest 6.8%, posicionándose entre los predictores más relevantes. La condición de becario, el modo de aplicación al ingreso, las notas promedio —particularmente del segundo semestre (3.7% en Random Forest, 0.18 en SVM)— y la condición de deuda también aportaron información relevante. Entre las variables sociodemográficas, el sexo, el estado civil y la carrera elegida presentan una influencia marginal en todos los modelos. La edad al momento de la inscripción, si bien generalmente marginal, alcanza 3.3% de importancia en Random Forest, reforzando la idea de que la deserción depende más del desempeño académico y el compromiso institucional que de factores estructurales o demográficos.

Discusión

Los modelos aplicados a la clasificación binaria obtuvieron performances similares tanto en AUC (0,91) y sensibilidad (0,91), como en accuracy, precisión y F1 score (0,88). Sí se logra identificar una muy leve superioridad a la hora de detectar a los verdaderos desertores con el modelo de RL que alcanzó 9.824 individuos. Con resultados tan parecidos, el ensamble de modelos no muestra una mejora respecto de los modelos vistos individualmente.

En el caso del problema multiclase, sí se aprecian diferencias. El modelo de ADD tiene un $F1_{weighted}=0,48$, muy bajo respecto del obtenido por otros modelos, sin embargo, supera en capacidad de detección de verdaderos desertores al ADD aplicado al target binario (9.777 vs 9.729). Los otros tres modelos tienen performances similares en cuanto a $F1_{weighted}$ (entre 0,72 y 0,78), sensibilidad (0,92), precisión y accuracy. No obstante, se aprecia una notoria superioridad de los ensambles en clasificación ternaria para detectar verdaderos desertores, donde Random Forest logra identificar 9.956 y AdaBoost alcanza la máxima performance con 9.979 verdaderos desertores identificados.

Este análisis comparativo donde se aplicaron diferentes modelos de machine learning con dos formas diferentes de abordar el problema (clasificación binaria y ternaria) de la deserción universitaria, nos permite volver a la pregunta inicial con hallazgos concretos. Por un lado vemos que todos los modelos de machine learning tienen una alta capacidad para identificar la clase target con el tipo de información provista por este dataset por lo cual tiene sentido aplicar y profundizar este tipo de análisis para diseñar estrategias de intervención temprana. Adicionalmente, la regresión logística obtuvo la mejor performance para problema binario y el ensamble por boosting AdaBoost la mejor performance de todos los modelos aplicados (binarios y ternarios) para este dataset. Retomando la pregunta sobre ¿qué variables permiten anticipar la probabilidad de deserción de un estudiante universitario? El análisis multivariado revela un patrón consistente y robusto: el rendimiento académico temprano, medido principalmente a través de los ratios de aprobación del primer año, constituye el predictor más potente de deserción universitaria, superando sistemáticamente a los factores sociodemográficos tradicionales. La convergencia de resultados entre modelos de distinta naturaleza (árboles binarios y ternarios, regresión logística, ensamble, SVM y Random Forest) valida esta conclusión y sugiere que las intervenciones institucionales deberían focalizarse en el acompañamiento académico durante los primeros semestres. El peso predictivo del pago de matrícula, consistente en todos los modelos evaluados, añade una dimensión económico-administrativa que no debería subestimarse: el compromiso financiero parece operar como proxy de motivación e integración institucional. Para futuras versiones, resultaría valioso incorporar variables actitudinales y de inserción social -como asistencia a clases, participación en tutorías o motivación declarada al ingresar- que complementen los indicadores cuantitativos de desempeño y permitan captar dimensiones no académicas que también inciden en la permanencia (James et al., 2021; Bishop & Nasrabadi, 2006).

Conclusión

En base a nuestros resultados, podemos concluir que los modelos de machine learning supervisado resuelven de manera confiable la predicción temprana de deserción universitaria a partir de datos académicos, demográficos y socioeconómicos del primer año de cursada. La regresión logística resultó más efectiva para clasificación binaria, mientras que los ensambles -particularmente AdaBoost- alcanzaron el mejor desempeño en clasificación ternaria, aunque con dificultades para discriminar entre Graduado y En Curso debido a la similitud de características académicas. El análisis de importancia de atributos reveló un patrón convergente entre todos los modelos: el rendimiento académico del primer año es el predictor más potente de deserción, superando a los factores sociodemográficos. Esta coincidencia entre algoritmos de distinta naturaleza sugiere que las intervenciones institucionales deberían focalizarse en el acompañamiento académico temprano, complementado con estrategias que fortalezcan el compromiso económico-administrativo. Este trabajo aporta evidencia empírica sobre la aplicabilidad de estos modelos en el contexto universitario, confirmando que sistemas de alerta temprana podrían contribuir a las estrategias de retención, priorizando la detección oportuna para maximizar las oportunidades de intervención.

Bibliografía

- Bishop, C. M., & Nasrabadi, N. M. (2006). Pattern recognition and machine learning. Springer.
- Chollet, F. (2021). Deep learning with Python. Simon and Schuster.
- Chen, C., Liaw, A., & Breiman, L. (2004). Using Random Forest to Learn Imbalanced Data. *University of California, Berkeley, Technical Report* 666.
- Comisión Nacional de Evaluación y Acreditación Universitaria (CONEAU). Permanencia de las y los estudiantes en la universidad. Buenos Aires: CONEAU-OEI, 2023. ISBN 978-987-3765-75-9.
- Cover, T. M., & Hart, P. E. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1).
- Duda, R. O., Hart, P. E., & Stork, D. G. (2001). Pattern Classification. Wiley.
- Freund, Y., & Schapire, R. E. (1997). A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting. *Journal of Computer and System Sciences*.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in R. Springer Nature.
- Mitchell, T. M. (1997). Machine learning. McGraw-Hill.
- Pustilnik, M. et al. Modelos de predicción de deserción de estudiantes universitarios en Argentina. XVIII Congreso de Tecnología en Educación y Educación en Tecnología, Universidad Nacional de Hurlingham, 2023.
- Secretaría de Políticas Universitarias (SPU). (2021). *Síntesis de Información. Estadísticas Universitarias 2020-2021*. Buenos Aires: Ministerio de Educación de la Nación. Disponible en: <http://bibliotecadigital.cin.edu.ar/handle/123456789/2835>
- Zhu, J., Rosset, S., Zou, H., & Hastie, T. (2009). Multi-class AdaBoost. *Statistics and Its Interface*, vol 2(nro. 3).